



Análisis de Tiros en la Bundesliga 2023/24

Asignatura: Últimas Tendencias en el Análisis de Datos Deportivos

Alba Martínez de la Hermosa

Daniel Lopez Paredes

Alonso González Romero

20 de May, 2026

Table of contents

1	Introducción	3
2	Preprocesamiento de los datos	4
2.1	Ingesta y Extracción de Datos Base	4
2.2	Filtrado de Contexto Dinámico (Open Play) y unificación de secuencias	5
2.3	Integración del Contexto Espacial (StatsBomb 360)	5
2.4	Selección de Variables	6
2.5	Exportación de los Datasets	6
3	Metodología	7
3.1	Configuración del entorno y carga de datos.	7
3.2	Definición del campo y constantes geométricas.	7
3.3	Creación de variables derivadas del 360.	8
3.3.1	Distancia al centro de la portería	8
3.3.2	Ángulo del balón respecto a los palos	8
3.3.3	Número de jugadores dentro del cono de visión	9
3.3.4	Distancia al rival más cercano dentro del ángulo de tiro	9
3.4	Fórmula: Cálculo de la probabilidad de meter gol.	10
3.5	Cálculo del incremento en la probabilidad de gol respecto a compañeros libres.	12
4	Resultados	13
4.1	Cálculo del incremento de la probabilidad	13
4.2	Recuento de jugadores con incremento positivo/negativo en media	14
4.3	Ránking de jugadores por media de incremento durante la temporada	14
4.4	Ránking de jugadores. Goles/Tiro	16
4.5	Ránking de jugadores. Pases/Asistencia	17
4.6	Hipótesis 1. ¿ Los goles tenían siempre un incremento = 0 o positivo?	18
4.7	Hipótesis 2. ¿Boniface y Wirtz registran mejores datos sobre incremento de la calidad de la ocasión?	18

1 Introducción

En el análisis avanzado del rendimiento ofensivo, el modelo de Expected Goals (xG) proporcionado por StatsBomb representa un estándar de alta precisión para medir la calidad de las ocasiones de gol. Sin embargo, por definición estructural del proveedor, la métrica `statsbomb_xg` está anclada de manera exclusiva a los eventos catalogados como disparos. Las acciones como los pases, carecen de este valor nativo en los registros. Esta limitación técnica nos impide evaluar directamente los escenarios contrafactuales, es decir, responder a los posibles “¿y si...?”.

Para analizar objetivamente la toma de decisiones de un jugador, no basta con medir la calidad del tiro que ejecutó, resulta imperativo cuantificar la calidad de las opciones de pase que descartó. Aprovechando que la estructura de los datos 360 nos permite trabajar en el modelado espacial de la oclusión, la solución metodológica óptima pasa por el desarrollo de un modelo probabilístico propio. Al construir una fórmula optimizando sus parámetros geométricos, somos capaces de “simular” el valor xG para cualquier coordenada del campo y en cualquier instante de la jugada. La implementación de este modelo unificado nos proporciona una métrica universal para comparar matemáticamente el tiro realizado frente al pase omitido. Gracias a esto, podemos identificar de forma empírica qué jugadores maximizan las probabilidades de éxito colectivo mediante buenas decisiones, y cuáles penalizan el ataque mostrando un mayor “ego” al finalizar jugadas de baja probabilidad ignorando a compañeros mejor posicionados.

2 Preprocesamiento de los datos

En este capítulo, el objetivo será construir el conjunto de datos inicial sobre el que vamos a calcular las métricas necesarias para hacer el estudio sobre las finalizaciones y sus tiros previos.

2.1 Ingesta y Extracción de Datos Base

En esta fase inicial, establecemos los cimientos de nuestro conjunto de datos analítico procesando la materia prima suministrada por StatsBomb. Dado el considerable volumen computacional que implica cargar el historial completo de eventos de una competición, implementamos una estrategia de filtrado en origen.

El proceso recorre secuencialmente el directorio de eventos procesados. Por cada partido, dividimos la información en dos flujos principales:

1. Disparos (Shots): Todos los tiros registrados por StatsBomb.
2. Pases Clave (Key Passes): Aquellos pases que están referenciados directamente como la acción previa a un disparo, garantizando la trazabilidad de la secuencia ofensiva.

Simultáneamente, extraemos y consolidamos los datos de cada partido cargando el diccionario de partidos y las alineaciones de cada uno. De esta manera podremos enriquecer posteriormente los análisis realizados.

Iniciando la ingesta de datos a nivel global...

```
--- REPORTE DE INGESTA DE DATOS (MUESTRA TOTAL) ---  
Total de disparos extraídos (Todos los equipos): 916  
Total de pases clave asociados extraídos: 690  
Total de partidos procesados: 34  
Total de registros de alineación procesados: 68
```

La diferencia entre la muestra total de disparos y los pases clave asociados es un patrón absolutamente normal. Esta reducción en los pases clave ocurre generalmente porque el evento general de disparo engloba finalizaciones que carecen de un pasador previo, tales como las acciones directas a balón parado (como penalties o tiros libre) o jugadas individuales donde el rematador finaliza tras crear su propia ventaja posicional.

Los modelos que construiremos en este trabajo se basan en la toma de decisiones tanto del lanzador como en la del pasador. Por lo tanto, el siguiente paso consiste en filtrar los disparos para quedarnos con aquellos producidos en situación de “Open Play”. Excluiremos jugadas precedidas de córner, penalties o tiros libres.

2.2 Filtrado de Contexto Dinámico (Open Play) y unificación de secuencias

Una vez consolidada la extracción de eventos, el siguiente paso de nuestro pipeline consiste en seleccionar la muestra para alinearla con los objetivos de la investigación a realizar. Dado que buscamos evaluar la toma de decisiones tácticas y la oclusión en escenarios de juego fluido, debemos descartar aquellas finalizaciones originadas a balón parado.

Para ello, aplicamos un filtro sobre la tipología específica del disparo (`shot.type`), conservando de manera exclusiva los remates categorizados como “Open Play”. Esta operación elimina de nuestra muestra poblacional los lanzamientos de penalti, los tiros libres directos y los saques de esquina directos, dejándonos tanto los tiros asistidos en dinámica como las jugadas individuales autónomas.

Posteriormente, construimos nuestro dataset relacional de secuencias ofensivas. Mediante una operación de unión (`join`), enlazamos estructuralmente los pases clave con sus correspondientes disparos en “Open Play”. Utilizando el identificador único del pase y la variable de enlace del disparo (`shot_key_pass_id`), logramos colapsar la secuencia temporal “Pase -> Tiro” en una única fila plana.

```
--- REPORTE DE SECUENCIAS OPEN PLAY ---
Total de disparos globales iniciales: 916
Total de pases clave iniciales: 690
Disparos aislados en 'Open Play': 882
Secuencias completas ensambladas (Pase -> Tiro en Open Play): 690
```

Los resultados nos proporcionan un mapa claro del volumen de datos útiles para nuestro estudio. Tras aplicar el filtro de juego dinámico, disponemos de una población exacta de 882 disparos en “Open Play”. Este será el conjunto de datos principal sobre el que evaluaremos la toma de decisiones, la ejecución y el posicionamiento de los rematadores, independientemente de si generaron su propia ventaja o si recibieron el balón de un compañero.

Por otro lado, la operación de unión relacional nos confirma un total de 690 secuencias completas (Pase clave -> Tiro). Esta submuestra representa nuestro núcleo analítico de mayor valor para estudiar la perspectiva de los asistidores, permitiéndonos evaluar el contexto previo a la finalización y analizar cómo sus pases habilitaron el espacio para el tirador.

Con los eventos de tiro filtrados y las secuencias tiro/pase construidas, el siguiente paso metodológico consistirá en dotar a estas acciones de su correspondiente contexto 360.

2.3 Integración del Contexto Espacial (StatsBomb 360)

La precisión de los modelos a construir posteriormente depende intrínsecamente de la disponibilidad de las coordenadas de los jugadores en los momentos críticos de la jugada. En esta fase, integramos la capa espacial StatsBomb 360, la cual captura las ubicaciones del ecosistema de jugadores en el instante exacto de la acción.

Para aislar nuestra muestra definitiva de estudio, implementamos dos operaciones de unión relacional restrictiva (`inner joins`) utilizando el identificador único del evento (`event_uid`):

1. **Disparos aislados:** Cruzamos la población de remates *Open Play* con la base de datos 360, descartando disparos que no tengan asignado freeze frame.
2. **Secuencias Pase/tiro:** Aplicamos dos uniones. Exigimos que, para analizar posteriormente estas secuencias, necesitamos el 360 del pase clave y del tiro. Si uno de los dos eventos carece del 360, la secuencia se elimina del análisis.

```

--- REPORTE DE INTEGRACIÓN ESPACIAL 360 ---
Tiros 'Open Play' originales: 882
Tiros 'Open Play' con contexto 360: 858
-----
Secuencias Pase->Tiro originales: 690
Secuencias perfectas (360 en Pase Y Tiro): 600

```

Para la rama del estudio centrada en el comportamiento de los finalizadores, la muestra definitiva consolida 858 disparos dinámicos con cobertura espacial absoluta. Esto representa una retención excepcional del 93.6% sobre el volumen ofensivo global inicial de la competición (916 tiros totales), alcanzando un asombroso 97.3% de eficacia si acotamos la métrica exclusivamente a los 882 remates originados en estricto Open Play.

Por otro lado, para el segundo enfoque de la investigación sobre la toma de decisiones de los pasadores, tenemos un total de 600 secuencias de pase y tiro con el 360 integrado. Esto significa que logramos retener el 87% de los 690 pases clave originales.

Con los dataset finales ya creados, el siguiente objetivo será elegir las variables necesarias para comenzar el análisis en profundidad para la creación de nuevas métricas.

2.4 Selección de Variables

En esta etapa final del pre-procesamiento, vamos a elegir las variables solamente necesarias de cada dataframe para reducir la dimensionalidad. Sólomente conservaremos las variables necesarias tanto para la creación de nuevas métricas como para la posterior validación.

2.5 Exportación de los Datasets

```

# Guardado final optimizado
df_matches_final.to_parquet("../data/processed/matches_metadata.parquet", index=False)
df_lineups_final.to_parquet("../data/processed/lineups_metadata.parquet", index=False)
df_shots_360_final.to_parquet("../data/processed/shots_360_analysis.parquet", index=False)
df_secuencias_final.to_parquet("../data/processed/shots_pass_360_analysis.parquet", index=False)

```

3 Metodología

En este capítulo, el objetivo reside en el cálculo de métricas sobre el contexto de los tiros basados en la posición de disparo y el contexto de la jugada a través del 360. A través de estas métricas, se define un sencillo modelo en el que se optimizan sus parámetros con el objetivo de ser lo más parecido posible a un modelo de xG.

Una vez tenemos nuestro propio modelo de xG, podremos calcular, para cualquier posición del campo y contexto de jugadores, la probabilidad de meter gol. Con esta característica, seremos capaces de calcular, para cada tiro, si hacer un pase a otro compañero era mejor opción en términos de mejora de la probabilidad de gol en nuestro modelo. Se trabajará de forma análoga para los pases previos a un tiro. Se calculará la probabilidad de gol desde el punto donde llegó el pase, y se comparará con la probabilidad si se hubiera pasado a cualquier otro compañero.

3.1 Configuración del entorno y carga de datos.

El primer paso para establecer nuestro motor de cálculo es inicializar el entorno de trabajo. Para ello, importamos las librerías fundamentales para la manipulación estructurada de datos y la ejecución de operaciones vectoriales optimizadas. Asimismo, incluimos los módulos matemáticos estándar que nos permitirán aplicar cálculos trigonométricos sobre el plano bidimensional del terreno de juego.

Una vez configurado el entorno, ingerimos los conjuntos de datos en formato optimizado (.parquet) que consolidamos durante la ingesta previa, garantizando que disponemos de la muestra exacta de acciones dinámicas en “Open Play” acompañadas de su contexto espacial (Freeze Frames).

3.2 Definición del campo y constantes geométricas.

Para realizar el modelado matemático de las trayectorias de los disparos y los pases, es fundamental anclar nuestro sistema sobre las coordenadas estándar proporcionadas por la especificación oficial de StatsBomb. El terreno de juego se define en un plano bidimensional continuo cuyas dimensiones abarcan desde 0 hasta 120 metros en el eje X (longitud) y desde 0 hasta 80 metros en el eje Y (anchura). De acuerdo con la estructuración geométrica del dato espacial, los eventos siempre se orientan asumiendo que el equipo atacante progresa del valor mínimo al valor máximo del eje X. Por consiguiente, nuestro objetivo a batir siempre se situará sobre la línea de fondo $x = 120$.

Con base en la ubicación de los postes, abstraeremos los elementos clave del campo utilizando la siguiente formalización matemática:

- Poste izquierdo: $P_{izq} = (120, 36)$
- Poste derecho: $P_{der} = (120, 44)$

- Centro de la portería: Obtenido mediante el punto medio de los postes, estableciendo $P_{cen} = (120, 40)$.- Volumen de oclusión (r): Para proyectar la oclusión espacial, modelaremos la silueta física de cada jugador dentro del Freeze Frame como un cuerpo circular con un radio $r = 0.5$ metros.

A continuación, inicializamos estas coordenadas y métricas de contorno como variables constantes (en mayúsculas por convención) para su consumo posterior en los algoritmos de probabilidad.

3.3 Creación de variables derivadas del 360.

Una vez creadas las variables de referencia del terreno de juego, el siguiente paso de la metodología consiste en la creación de métricas tácticas explicativas sobre la posición de disparo. Aprovechando la posición desde la que se golpea y el contexto 360 de ese momento, vamos a extraer cuatro métricas para cada posible disparo desde una posición determinada del campo.

3.3.1 Distancia al centro de la portería

La distancia al objetivo es, históricamente, la variable de mayor peso en cualquier modelo de probabilidad de éxito. Utilizando el vector location del evento principal, calcularemos la distancia euclidiana exacta entre el origen del disparo (o pase) y nuestra constante central de la portería $P_{cen} = (120, 40)$. Para un punto de origen (x, y) , la distancia d se define como:

$$d = \sqrt{(120 - x)^2 + (40 - y)^2}$$

Implementaremos este cálculo mediante una función modular en Python diseñada para recibir un array genérico de dos posiciones $[x, y]$. Este enfoque arquitectónico nos permite aplicar el cálculo geométrico tanto sobre la ubicación central del evento, como reutilizar la misma función de manera iterativa sobre las coordenadas individuales de cada jugador presente en los objetos anidados del freeze_frame. De este modo, garantizamos la consistencia matemática a lo largo de todo el análisis espacial.

player_name	location	dist_centro_porteria
Granit Xhaka	[92.2, 27.1]	30.6472
Timo Werner	[107.0, 23.2]	21.2424
Jonas Hofmann	[96.2, 44.8]	24.2792
Ikoma Lois Openda	[101.0, 28.8]	22.0554
Benjamin Henrichs	[98.1, 29.8]	24.1588

3.3.2 Ángulo del balón respecto a los palos

El ángulo de tiro, o shooting angle, define la amplitud de la “ventana” de gol que el rematador percibe en el momento del impacto. Matemáticamente, este se define como el ángulo formado por dos vectores que parten desde la ubicación del balón (x, y) hacia los dos postes de la portería, situados en las coordenadas $P_{izq} = (120, 36)$ y $P_{der} = (120, 44)$.

Una mayor amplitud angular implica una mayor superficie de portería visible y, por tanto, una mayor probabilidad técnica de éxito. Para su cálculo, implementaremos una función que utilice el producto escalar de los vectores directores, obteniendo el ángulo θ mediante la siguiente relación:

$$\cos(\theta) = \frac{\vec{V}_1 \cdot \vec{V}_2}{|\vec{V}_1| \cdot |\vec{V}_2|}$$

Donde $\vec{V}_1$ y $\vec{V}_2$ son los vectores desde el balón a los postes izquierdo y derecho, respectivamente.

player_name	location	dist_centro_porteria	angulo_tiro
Granit Khaka	[92.2, 27.1]	30.6472	13.5438
Timo Werner	[107.0, 23.2]	21.2424	13.4388
Jonas Hofmann	[96.2, 44.8]	24.2792	18.3666
Ikoma Loïs Openda	[101.0, 28.8]	22.0554	17.9057

3.3.3 Número de jugadores dentro del cono de visión

Para determinar si un jugador rival está bloqueando físicamente el ángulo de tiro, debemos modelar el “cono” como un triángulo cuyos vértices son: la posición del balón en posesión (S) y los dos postes de la portería, $P_{izq} = (120, 36)$ y $P_{der} = (120, 44)$.

Un punto P (la posición de un rival) se encuentra dentro de este triángulo si cumple simultáneamente las condiciones de orientación respecto a los vectores que definen sus lados. La forma más robusta y eficiente de calcular esto en programación es mediante el producto vectorial en 2D. Para cada vector de lado del triángulo $\vec{AB}$ y el punto P , el signo del producto vectorial $(B_x - A_x)(P_y - A_y) - (B_y - A_y)(P_x - A_x)$ nos indica si el punto está a la izquierda o a la derecha de la línea AB . Si al realizar esta operación para los tres lados del triángulo (SP_{izq} , $P_{izq}P_{der}$, y $P_{der}S$) los signos son consistentes (todos positivos o todos negativos), el punto P está contenido dentro del área de visión. A continuación, implementamos la función que procesa el array de diccionarios `freeze_frame` (que contiene la información de los jugadores en ese instante) para filtrar y contar a los rivales que cumplan esta condición.

player_name	compañeros_en_cono	rivales_en_cono	jugadores_en_cono
Granit Khaka	0	1	1
Timo Werner	0	1	1
Jonas Hofmann	0	3	3
Ikoma Loïs Openda	0	2	2

3.3.4 Distancia al rival más cercano dentro del ángulo de tiro

Una vez que hemos filtrado los jugadores que ocupan el cono de visión del lanzador, calcularemos la intensidad de la presión defensiva. Para ello, buscamos el valor mínimo de las distancias euclidianas entre la posición del lanzador $S = (x_s, y_s)$ y la posición de cada jugador rival $R_i = (x_i, y_i)$ que se encuentre dentro del cono, según la siguiente expresión:

$$d_{min} = \min_{i \in \text{cono}} \sqrt{(x_i - x_s)^2 + (y_i - y_s)^2}$$

Si el conjunto de jugadores en el cono está vacío, asignaremos un valor suficientemente alto: 60.0

	player_name	jugadores_en_cono	dist_rival_cercano_cono
0	Granit Xhaka	1	11.353
1	Timo Werner	1	17.2666
2	Jonas Hofmann	3	6.59317
3	Ikoma Loïs Openda	2	1.35084

3.4 Fórmula: Cálculo de la probabilidad de meter gol.

Antes de realizar la fórmula para estimar la probabilidad de meter gol según el contexto y distancia del lanzador a portería, vamos a revisar los rangos de valores de las 4 métricas numéricas recién calculadas.

Resumen estadístico de las nuevas métricas:

	min	max	mean	50%	null_count
dist_centro_porteria	3.32415	62.67	17.9219	17.3416	0
angulo_tiro	6.591	103.625	26.4734	21.2997	0
jugadores_en_cono	0	9	1.7669	1	0
dist_rival_cercano_cono	0.384934	60	14.8851	9.02443	0

Observamos que hay valores de rival más cercano a 60, eso es debido a que, si no hay jugadores dentro del ángulo, ponemos esa distancia para evitar poner 0, lo que haría que el algoritmo detectara una presión muy fuerte sobre el jugador, algo irreal viendo las características de la situación

Una vez asegurada la explicabilidad de cada métrica en los casos más extremos, creamos la fórmula base a utilizar:

$$P(Gol) = \exp \left(-\lambda \cdot d_{porteria} - \alpha \cdot N_{cono} - \frac{1 - \alpha}{d_{rival}} \right)$$

- Distancia al centro de la portería ($d_{porteria}$): Al estar en el exponente con signo negativo, a mayor distancia desde la ubicación del disparo hasta el centro de la portería (120, 40), la probabilidad cae exponencialmente. Es el factor de “decaimiento” principal.
- Jugadores en el cono (N_{cono}): Representa la oclusión física. A mayor número de jugadores identificados en el freeze_frame dentro del triángulo de tiro, mayor es el valor sustraído del exponente, lo que reduce la probabilidad de gol al aumentar la probabilidad de bloqueo.
- Presión del rival más cercano (d_{rival}): Actúa como un factor de urgencia técnica. Al ser una función inversa ($\frac{1}{d_{rival}}$), cuanto menor sea la distancia al defensor (es decir, mayor presión), más grande es el término sustraído, lo que penaliza la probabilidad debido a la reducción del tiempo y espacio para una ejecución limpia.

Una vez hemos definido la fórmula a utilizar, ahora nuestro objetivo es definir la mejor combinación de parámetros que consigan mejor rendimiento respecto al modelo base de xG

Mejor Lambda: 0.1790

Mejor Alpha: 0.1741

Correlación máxima con xG StatsBomb: 0.6591

El término $-0.179 \cdot d_{porteria}$ representa el decaimiento base. Por cada metro de distancia adicional que te alejas de la portería, el exponente sufre una penalización constante de 0.179. Es el esqueleto del modelo: un tiro desde 10 metros siempre tendrá, de base, un exponente de -1.79 antes de mirar qué hacen los defensas.


El término $-0.1741 \cdot N_{cono}$ castiga cada jugador que se interpone en tu ángulo de visión hacia los palos. Como λ y α son casi idénticos (0.179 frente a 0.1741), el modelo nos está diciendo que tener a un jugador más bloqueando la visión castiga tu probabilidad de gol casi lo mismo que alejar el tiro 1 metro más atrás.

El término $-\frac{0.8259}{d_{rival}}$ es el más agresivo y el que define la urgencia de la toma de decisión. Al estar la distancia del rival dividiendo, su efecto se dispara cuando el defensor está muy cerca: Si el rival está a 5 metros (poca presión), la penalización es pequeña: $0.8259/5 = 0.165$. Si el rival te está encimando a 1 metro (presión extrema), la penalización explota a 0.8259. Para compensar esa presión de tener a un tío a un metro, tendrías que acercar el balón casi 4.6 metros hacia la portería ($0.8259/0.179$). Esto demuestra que el modelo pondera muchísimo el tiempo y espacio de ejecución: un tiro lejano pero totalmente libre de marca puede tener mejor xG que un tiro más cercano pero con un central echándose encima.

--- RESULTADOS DE VALIDACIÓN ---

Correlación de Pearson: 0.6556

Coeficiente de determinación (R^2): 0.2876



3.5 Cálculo del incremento en la probabilidad de gol respecto a compañeros libres.

En esta sección, el objetivo será calcular una métrica que nos explique la toma de decisión tanto de delanteros como de los asistentes (último pase). Para cada tiro/pase clave, evaluaremos dicho freeze-frame para identificar a todos los compañeros que pudieran recibir un pase desde esa posición. Si el pase no es interceptado en línea recta suponiendo que los defensores tienen un pequeño radio de 1 metro, entonces, calculamos la probabilidad de meter gol desde la posición del compañero. Haremos esto para cada compañero visible y nos quedaremos con la probabilidad máxima del mejor compañero visible. Con esta probabilidad, seremos capaces de, para cada pase/tiro, calcular el incremento en la probabilidad si se hubiera tomado otra decisión.

Ahora, calculamos cuántos pases y tiros mejorarían si se tomara otra decisión:

--- RESUMEN DE MEJORA EN DECISIONES ---

% de tiros donde pasar habría dado más probabilidad: 48.72%

% de pases donde otra opción habría sido mejor: 24.17%

Por último, nos cargamos ambos dataframes de nuevo para la parte de resultados:

4 Resultados

Para comenzar la sección de resultados importamos primeramente los parquets generados durante la sección de metodología.

4.1 Cálculo del incremento de la probabilidad

Para los análisis que se van a realizar en esta sección, primero obtendremos un nuevo valor llamado **incremento**, tanto para *df_passes*, como para *df_shots*.

Este valor es el resultado de la resta: *fórmula base - mejor probabilidad de tiro/probabilidad de pase y tiro*.

De esta forma, obtenemos el valor añadido (positivo o negativo) de la toma de decisiones de los jugadores, frente a la mejor opción que tenían en el momento. Se evalúa cómo aumenta o disminuye la probabilidad de marcar un gol, o de dar un pase que acabe en gol según las decisiones tomadas.

--- Incremento en Tiros (primeras 5 filas) ---

	player_name	formula_base	mejor_prob_posible	incremento
0	Granit Xhaka	0.00323834	0.1874	-0.184161
1	Timo Werner	0.0178755	0.0758835	-0.058008
2	Jonas Hofmann	0.00678159	0.085991	-0.0792094
3	Ikoma Loïs Openda	0.00739087	0.0959604	-0.0885695
4	Benjamin Henrichs	0.00773866	0	0.00773866

--- Incremento en Pases (primeras 5 filas) ---

	player_name_pass	formula_base	prob_opcion_pase_tiro	incremento
0	Timo Werner	0.0793588	0	0.0793588
1	David Raum	0.289966	0	0.289966
2	Victor Okoh Boniface	0.278733	0	0.278733
3	Jonas Hofmann	0.0227644	0	0.0227644
4	Jonas Hofmann	0.257728	0	0.257728

4.2 Recuento de jugadores con incremento positivo/negativo en media

--- RECuento TOTAL: TIROS ---

Total de jugadores que han tirado: 176

Suman (Positivo): 80 jugadores (45.5%)

Restan (Negativo): 96 jugadores (54.5%)

--- RECuento TOTAL: PASES ---

Total de jugadores que han pasado: 144

Suman (Positivo): 126 jugadores (87.5%)

Restan (Negativo): 18 jugadores (12.5%)

4.3 R anking de jugadores por media de incremento durante la temporada

A continuaci n, vamos a calcular el Top 10 de jugadores del Bayer Leverkusen respecto a su incremento/decremento de la oportunidad de gol durante toda la temporada. Para ello:

TOP MEJORES DECISORES DEL BAYERN LEVERKUSEN

player_name	total_tiros	total_goles	incremento_medio
Jonathan Tah	24	3	0.0268015
Amine Adli	25	4	-0.00943229
Jeremie Frimpong	55	8	-0.0242405
Piero Mart�n Hincapi� Reyna	18	1	-0.0249566
Robert Andrich	21	4	-0.0259634
Victor Okoh Boniface	74	10	-0.0260872
Borja Iglesias Quintas	7	0	-0.0323069
Patrik Schick	39	6	-0.044019
Florian Wirtz	67	10	-0.0467667
Nathan Tella	20	5	-0.0531519

Observamos que el  nico jugador en positivo es Jonathan Tah. Este jugador, consigue, en media, durante la temporada, un incremento medio positivo. Por lo tanto, Jonathan Tah se considera el mejor decisor del Bayern Leverkusen de la temporada 23-24 ya que en media, sus decisiones de tiro eran las mejores en el momento exacto del disparo.

TOP PEORES DECISORES DEL BAYERN LEVERKUSEN

player_name	total_tiros	total_goles	incremento_medio
Edmond Fay�al Tapsoba	12	0	-0.102302
Exequiel Alejandro Palacios	19	2	-0.0818845
Josip Stani�i�	9	3	-0.0814992
Alejandro Grimaldo Garc�a	52	8	-0.0760148
Granit Xhaka	42	3	-0.0709625

Jonas Hofmann		61		4		-0.0692437	
Adam Hložek		19		2		-0.0628835	
Nathan Tella		20		5		-0.0531519	
Florian Wirtz		67		10		-0.0467667	
Patrik Schick		39		6		-0.044019	

Respecto a los peores decisores, destaca Tapsoba, que realizó 12 tiros durante la temporada logrando un incremento medio negativo de un 10% aproximadamente. Por lo tanto, se puede concluir que dicho jugador fue considerablemente el que peores decisiones tomaba en cuanto a tiro en el vestuario del Leverkusen.

Una vez realizado el ranking para los tiradores, vamos a evaluar la calidad de la toma de decisión de los asistentes previos a un tiro, con el objetivo de revisar si esta decisión fue la mejor en el momento del pase.

TOP MEJORES DECISORES DEL BAYERN LEVERKUSEN. PASES

player_name_pass		total_pases		total_asistencias		incremento_medio	
:-----		:		:		:	
Nathan Tella		13		2		0.339633	
Alejandro Grimaldo García		62		10		0.193084	
Jeremie Frimpong		35		4		0.154515	
Josip Stanišić		12		1		0.146057	
Victor Okoh Boniface		21		8		0.135094	
Jonas Hofmann		66		5		0.124051	
Odilon Kossonou		9		0		0.113535	
Amine Adli		18		4		0.108637	
Adam Hložek		7		2		0.0818633	
Borja Iglesias Quintas		5		0		0.0815416	

Observamos que Nathan Tella, con 13 pases clave durante la temporada fue el mejor pasador clave que tuvo el equipo, ya que incrementaba la probabilidad de gol hasta en un 33% los pases que realmente realizó, considerándose así uno de los jugadores con mejor capacidad de toma de decisión en ese momento del juego.

Grimaldo, Frimpong, Stanisic, Boniface, Hofmann y Kossonou también logran un incremento medio mayor del 10%, lo que los sitúa como buenos decisores en el paso previo a un tiro.

TOP PEORES DECISORES DEL BAYERN LEVERKUSEN. PASES

player_name_pass		total_pases		total_asistencias		incremento_medio	
:-----		:		:		:	
Patrik Schick		7		0		-0.0581995	
Granit Khaka		38		0		0.0314937	
Jonathan Tah		5		1		0.0326545	
Edmond Fayçal Tapsoba		5		1		0.0531	
Robert Andrich		19		1		0.0531534	
Exequiel Alejandro Palacios		22		3		0.0724208	
Florian Wirtz		59		9		0.0765785	
Borja Iglesias Quintas		5		0		0.0815416	
Adam Hložek		7		2		0.0818633	
Amine Adli		18		4		0.108637	


Respecto a los peores decisores, destacamos a Patrik Schick, que, en media, su incremento es un 5% negativo, es decir, que en media, sus decisiones empeoraban la calidad del tiro en un 5%.

4.4 R anking de jugadores. Goles/Tiro

--- TOP JUGADORES: GOLES POR TIRO E INCREMENTO ---

player_name	total_tiros	total_goles	goles_por_tiro	incremento
Josip Stani�i�	9	3	0.333333	-0.05
Nathan Tella	20	5	0.25	-0.05
Robert Andrich	21	4	0.190476	-0.05
Amine Adli	25	4	0.16	-0.05
Alejandro Grimaldo Garc�a	52	8	0.153846	-0.05
Patrik Schick	39	6	0.153846	-0.05
Florian Wirtz	67	10	0.149254	-0.05
Jeremie Frimpong	55	8	0.145455	-0.05
Victor Okoh Boniface	74	10	0.135135	-0.05
Jonathan Tah	24	3	0.125	0.00

Parece no existir una relaci n entre el incremento de probabilidad y el ratio tiros/goles. Lo vemos en un gr fico:




Observamos que realmente, no existe una relaci n entre ambas variables.

4.5 R anking de jugadores. Pases/Asistencia

--- TOP JUGADORES: ASISTENCIAS POR E INCREMENTO ---

player_name_pass	total_pases	total_asistencias	asistencias_por_pase
Victor Okoh Boniface	21	8	0.380952
Adam Hlo�ek	7	2	0.285714
Amine Adli	18	4	0.222222
Edmond Fay�al Tapsoba	5	1	0.2
Jonathan Tah	5	1	0.2
Alejandro Grimaldo Garc�a	62	10	0.16129
Nathan Tella	13	2	0.153846
Florian Wirtz	59	9	0.152542
Exequiel Alejandro Palacios	22	3	0.136364
Jeremie Frimpong	35	4	0.114286


Tampoco parece haber relaci n. Lo comprobamos con una gr fica y el coeficiente de correlaci n lineal.



Aunque parece haber una suave relaci n positiva, es demasiado baja con un p-valor demasiado alto. Tampoco hay correlaci n entre dar m s asistencias y tener mejor  ndice de decisi n.

4.6 Hipótesis 1. ¿ Los goles tenían siempre un incremento = 0 o positivo?

Vamos a comparar la distribución del incremento de probabilidad en 2 grupos separados. Los tiros que fueron gol y los que no. Vamos a ver si en los goles, era muy claro o había incluso opciones mejores.



P-Valor: 0.0023

Media Incremento (Gol): -0.0056

Media Incremento (No Gol): -0.0522

Existe evidencia significativa para determinar que, en los tiros que fueron gol, se estaba tomando, como mínimo, una de las mejores decisiones.

Respecto a los tiros que no acabaron en gol, se observa que en media, habían opciones mejores que aumentaban la probabilidad un 5%.

4.7 Hipótesis 2. ¿Boniface y Wirtz registran mejores datos sobre incremento de la calidad de la ocasión?

Respecto a esta segunda hipótesis, ya ha sido validada al revisar los datos sobre los mejores tiradores. No.